MEMORIA PROYECTO

DATOS MUNDIALES

Unicorn Academy

Proyecto Integrador Unicorn Academy

Edición 7.0

Integrantes:

- Gómez Lucas
- Rey Gonzalo
- Vázquez Débora

Febrero 2025

Índice

1. Contexto y Objetivo del Proyecto

El proyecto **Datos Mundiales** es un **proyecto integrador** que nos permite consolidar los conceptos aprendidos a lo largo del bootcamp Data Analytics de **Unicorn Academy** y aplicarlos en un desafío real de análisis de datos. Como equipo, trabajamos de manera colaborativa utilizando **SQL** y **Python** en un entorno profesional simulado.

En un mundo globalizado, donde la toma de decisiones basadas en datos es fundamental, nos enfocamos en centralizar información idiomática, demográfica, geográfica, económica y política mediante la base de datos ***"proyecto_integrador"*** en **MySQL**. Esto nos permite analizar y comparar datos de manera precisa y eficiente.

Para alcanzar estos objetivos, importamos la base de datos con scripts SQL, conectamos Python con MySQL y desarrollamos consultas, integrando ambas herramientas en un flujo de trabajo robusto.

2. Herramientas y Software

El proyecto utiliza las siguientes herramientas y bibliotecas:

- MySQL Workbench: Creación de base de datos e importación de las tablas.
- Jupyter Notebook: Software con entorno de lenguaje Python para el desarrollo y previsualización de análisis.
- Bibliotecas de Python: mysql.connector, pandas, matplotlib, empleadas para el procesamiento de datos, generación de gráficos.
- Github: Almacenar el código en el repositorio de Github.

3. Datos Utilizados

Para el desarrollo de este proyecto integrador, se utilizaron tres conjuntos de datos fundamentales en formato "***.sql***" : "***world_city***", "***world_country***" y "***world_countrylanguage***", proporcionados por Unicorn Academy. Estos datasets fueron entregados con el proceso de **ETL** (Extracción, Transformación y Carga) previamente realizado, lo que facilitó el trabajo al contar con datos limpios y listos para su análisis.

4. Importación de la Base de Datos en MySQL

Los conjuntos de datos fueron importados a la base de datos "*proyecto_integrador*" en MySQL utilizando los scripts "***.sql***" propuestos. La importación se llevó a cabo a través del asistente de MySQL Workbench, lo que permitió cargar las tablas correspondientes de manera eficiente.

Para llevar adelante la importación se pueden seguir los pasos detallados en la **"Guía para importar Base de Datos en MySQL Workbench"** anexa a esta memoria. En la misma, también se explica cómo duplicar la base de datos, con la finalidad de mantener los datos en crudo en una base original y luego trabajar con las transformaciones en otra base, quedando así la primera como copia de respaldo.

5. Análisis Exploratorio inicial de Datos

Las tablas importadas contienen información clave sobre ciudades, países y lenguas. Las mismas fueron exploradas inicialmente en MySQL Workbench para realizar consultas y análisis preliminares, que permitieron entender con qué información estamos trabajando y sacar las primeras informaciones y relaciones, a saber:

- La tabla "*country*" cuenta con 15 columnas y 239 filas y contiene información sobre nombre de países, continentes, regiones, superficie, población, forma de gobierno, presidentes, entre otras.
- La tabla "*city*" cuenta con 5 columnas y 4.079 filas y contiene información sobre población de algunas ciudades de cada país. Esta tabla contiene una columna de CountryCode (código de país de 3 letras) que permite relacionarla con la tabla "*country*" que contiene una columna con información equivalente.
- La tabla "*countrylanguage*" cuenta con 4 columnas y 984 filas y contiene información sobre cómo se distribuyen en porcentaje los idiomas dentro de cada país, detallando los distintos idiomas que se hablan, y si son oficiales o no. Esta tabla también contiene una columna de CountryCode que permite la relación con la tabla "*country*".
- Los nombres de los países y continentes se encuentran correctamente escritos y no hay duplicados.
- La información de los datasets proporcionados no está actualizada, ya que por ejemplo al consultar sobre el presidente de Argentina, la consulta arrojó Fernando de la Rua y su mandato fue entre 1999-2001.
- La tabla "*country*" posee algunas columnas con datos nulos (ej: año de independencia, expectativa de vida), pero las mismas no serán utilizadas para las consultas de este proyecto.

```
SELECT * FROM proyecto_integrador.city;
SELECT * FROM proyecto_integrador.country;
SELECT * FROM proyecto_integrador.countrylanguage;
SELECT distinct(continent) FROM country;

SELECT
      count(Code) as CantPaises,
      count(distinct(Code)) as CantPaisesUnicos
FROM country;

SELECT HeadOfState FROM country WHERE name = 'Argentina';
```

6. Conexión a MySQL desde Python

a. Carga de Bibliotecas

Antes de comenzar a trabajar con Python, importamos las bibliotecas.

- Utilizaremos **mysql.connector** para hacer la conexión desde Python a la base de datos en MySQL.
- Utilizaremos **pandas** para poder trabajar con Data Frames.
- Utilizaremos **matplotlib.pyplot** para graficar los resultados.

```
import mysql.connector
import pandas as pd
import matplotlib.pyplot as plt
from mysql.connector import Error
```

b. Definición de Funciones

En primer lugar, definimos la función "***obtener_datos_sql***" que nos permitirá hacer todas las consultas que queramos sólamente variando el input de la misma.

Utilizaremos un bloque "***try-except***" por si al ejecutar los comandos ocurre un error, y para ello habremos importado con anterioridad la clase "***Error***" de la biblioteca mysql.connector.

Dentro del bloque de código de la función, para hacer una conexión a una base de datos a través de la biblioteca mysql.connector es necesario conectarse al servidor con las mismas credenciales utilizadas en MySQL Workbench.

Para verificar que la conexión es exitosa utilizamos el comando "***.is_connected()***", que valida la misma. Luego utilizamos el comando "***.cursor()***" que nos permite ejecutar consultas en lenguaje SQL y recuperar las salidas de las mismas desde la base de datos seleccionada. El comando "***.execute(query)***" ejecuta la consulta que tiene como argumento, en nuestro caso una variable que iremos cambiando en función de cada consulta. Con el comando "***cursor.description***" recuperamos de la base de datos la información de las columnas, y con el comando "***.fetchall()***" obtenemos todos los resultados.

El resultado, junto con los nombres de las columnas, se vuelca en un data frame que será la solución para cada consulta que ejecutemos.

Antes de cerrar la conexión, cerramos el bloque "***try-except***" con un código que nos mostrará un texto indicando si ocurrió un error, identificando el tipo de error ocurrido.

Finalmente, si el código puede realizar la conexión con la base de datos, se cierra el cursor, se cierra la conexión y lo informa.

```
def obtener_datos_sql(query):
    try:
        conexion = mysql.connector.connect(host="localhost",
user="USER", password="PASSWORD",database= "proyecto_integrador")

        if conexion.is_connected():
            print("Conexión exitosa a la base de datos")
            cursor = conexion.cursor()
            cursor.execute(query)
            columnas = [i[0] for i in cursor.description
            resultados = cursor.fetchall()
            df = pd.DataFrame(resultados, columns=columnas)
            return df

    except Error as e:
        print(f"Ocurrió un error: {e}")
        return None

    finally:
        if conexion.is_connected():
            cursor.close()
            conexion.close()
            print("Conexión cerrada")
```

En segundo lugar, para poder actualizar datos dentro de la base de datos, definimos la función "***actualizar_datos_sql***", cuyo argumento será un código de UPDATE en lenguaje SQL. Inicialmente, se intentó utilizar la función "***obtener_datos_sql***" para actualizar la información en la base de datos. Sin embargo, al ejecutar esta función con una instrucción UPDATE, se produjo un error, ya que este tipo de instrucción no genera un conjunto de resultados de salida. La función "***obtener_datos_sql***" quedó diseñada exclusivamente para recuperar datos, no para modificarlos. Para solucionar este problema, se desarrolla una nueva función que se encarga específicamente de actualizar los registros en la base de datos.

La nueva función tiene la misma lógica que la anterior para la conexión y consulta, sólo que en esta se agrega el comando "***.commit()***" para efectuar los cambios en la base de datos.

```
def actualizar_datos_sql(update):
    try:
        conexion = mysql.connector.connect(host="localhost",
user="USER", password="PASSWORD",database= "proyecto_integrador")

        if conexion.is_connected():
            print("Conexión exitosa a la base de datos")
            cursor = conexion.cursor()
            cursor.execute(update)
```

```
            conexion.commit()
            print("Datos actualizados")
    except Error as e:
        print(f"Ocurrió un error: {e}")
        return None

    finally:
        if conexion.is_connected():
            cursor.close()
            conexion.close()
            print("Conexión cerrada")
```

c. Consideración muy importante

Este código posibilita al usuario a hacer modificaciones en la base de datos. Para resguardarse de los cambios, antes de ingresar a la misma , es recomendable hacer un backup para salvar los datos originales de la base de datos. Para ello se pueden seguir los pasos detallados en la guía anexa detallada en el capítulo “Importación de la Base de Datos en MySQL” de esta memoria.

Teniendo definidas las funciones, lo que queda es ir definiendo para las variables de entrada de las mismas, las consultas en lenguaje SQL con las que queramos operar en la base de datos.

d. Consultas y visualizaciones

`Ejercicio 1: Escribe una consulta para mostrar el nombre y la población de todos los países del continente europeo`

```
consulta_sql1 = "SELECT Name as Pais, population as Poblacion FROM
proyecto_integrador.country WHERE continent = 'Europe';"

data_frame1 = obtener_datos_sql(consulta_sql1)
if data_frame1 is not None:
    print(data_frame1)
```

```
Conexión exitosa a la base de datos

Conexión cerrada

      Pais                          Poblacion
0     Albania                       3401200
1     Andorra                       78000
2     Austria                       8091800
3     Belgium                       10239000
```

```
4     Bulgaria                        8190900
5     Bosnia and Herzegovina          3972000
6     Belarus                         10236000
7     Switzerland                     7160400
8     Czech Republic                  10278100
9     Germany                         82164700
10    Denmark                         5330000
11    Spain                           39441700
12    Estonia                         1439200
13    Finland                         5171300
14    France                          59225700
15    Faroe Islands                   43000
16    United Kingdom                  59623400
17    Gibraltar                       25000
18    Greece                          10545700
19    Croatia                         4473000
20    Hungary                         10043200
21    Ireland                         3775100
22    Iceland                         279000
23    Italy                           57680000
24    Liechtenstein                   32300
25    Lithuania                       3698500
26    Luxembourg                      435700
27    Latvia                          2424200
28    Monaco                          34000
29    Moldova                         4380000
30    Macedonia                       2024000
31    Malta                           380200
32    Netherlands                     15864000
33    Norway                          4478500
34    Poland                          38653600
35    Portugal                        9997600
36    Romania                         22455500
37    Russian Federation              146934000
38    Svalbard and Jan Mayen          3200
39    San Marino                      27000
40    Slovakia                        5398700
41    Slovenia                        1987800
42    Sweden                          8861400
43    Ukraine                         50456000
44    Holy See (Vatican City State)   1000
45    Yugoslavia                      10640000
```

Con la biblioteca **Matplotlib.pyplot** haremos visualizaciones a partir de las salidas de las consultas.

Debido a la dificultad de graficar en una misma escala a todos los países según su población, filtramos el data frame en un Top 10 de países con mayor población en Europa. Luego ordenamos el data frame, y generamos una nueva columna dividiendo "***Poblacion***" por 1.000.000 para poder lograr una mejor representación gráfica.

```
data_frame1_Top10 = data_frame1.nlargest(10, 'Poblacion')
```

```
data_frame1_Top10 = data_frame1_Top10.sort_values(by='Poblacion',
ascending=True)
```

```
data_frame1_Top10['Poblacion_millones'] =
data_frame1_Top10['Poblacion']/1000000
```

```
plt.figure(figsize=(10, 8))
barras = plt.barh(data_frame1_Top10['Pais'],
data_frame1_Top10['Poblacion_millones'], color='darkviolet', edgecolor =
"purple", linewidth = 2)
plt.title('Población de Países')
plt.xlabel('Población (millones)')
plt.ylabel('País')

# generamos las etiquetas en las barras con un bucle
for b in barras:
    xval = b.get_width()
    plt.text(xval+0.5, b.get_y() + b.get_height()/2, f"{xval:.2f}",
ha='left', va='center')

plt.grid(axis='x')
plt.show()
```

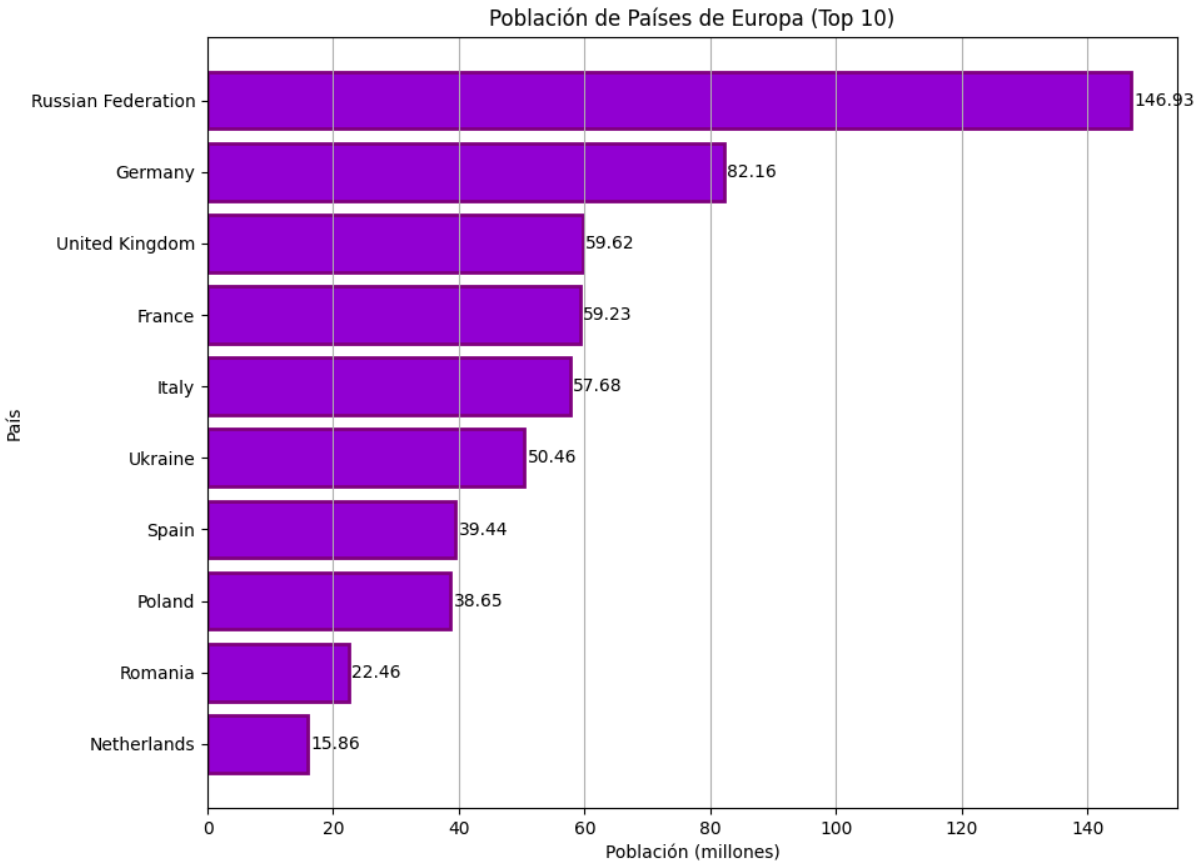

Ejercicio 2: Escribe una consulta para mostrar los nombres y las áreas de superficie de los cinco países más grandes del mundo (en términos de área de superficie).

```
consulta_sql2 = "SELECT Name as Pais, SurfaceArea as Superficie_km2 FROM
country ORDER BY SurfaceArea desc limit 5;"

data_frame2 = obtener_datos_sql(consulta_sql2)
if data_frame2 is not None:
    print(data_frame2)
```

```
Conexión exitosa a la base de datos
Conexión cerrada
                Pais Superficie_km2
0  Russian Federation    17075400.00
1          Antarctica    13120000.00
2              Canada     9970610.00
3               China     9572900.00
4       United States     9363520.00
```

Creamos una nueva columna dividiendo "***Superficie_km2***" por 1.000.000 para representar mejor la escala del gráfico.

```
data_frame2['Superficie_millones_km2'] =
data_frame2['Superficie_km2']/1000000
```

Ordenamos para luego graficar de mayor a menor el Top 5 de países según superficie.

```
data_frame2 = data_frame2.sort_values(by='Superficie_millones_km2',
ascending=True)
```

```
plt.figure(figsize=(10, 5))
barras = plt.barh(data_frame2['Pais'],
data_frame2['Superficie_millones_km2'], color='darkviolet',
edgecolor="purple", linewidth=2)
plt.title('Superficie de Países (Top 5)')
plt.xlabel('País')
plt.ylabel('Superficie (millones km²)')

# generamos las etiquetas en las barras con un bucle
for b in barras:
    xval = b.get_width()
    plt.text(xval +0.1, b.get_y() + b.get_height()/2, f"{xval:.2f}",
ha='left', va='center')

plt.grid(axis='x')
plt.show()
```

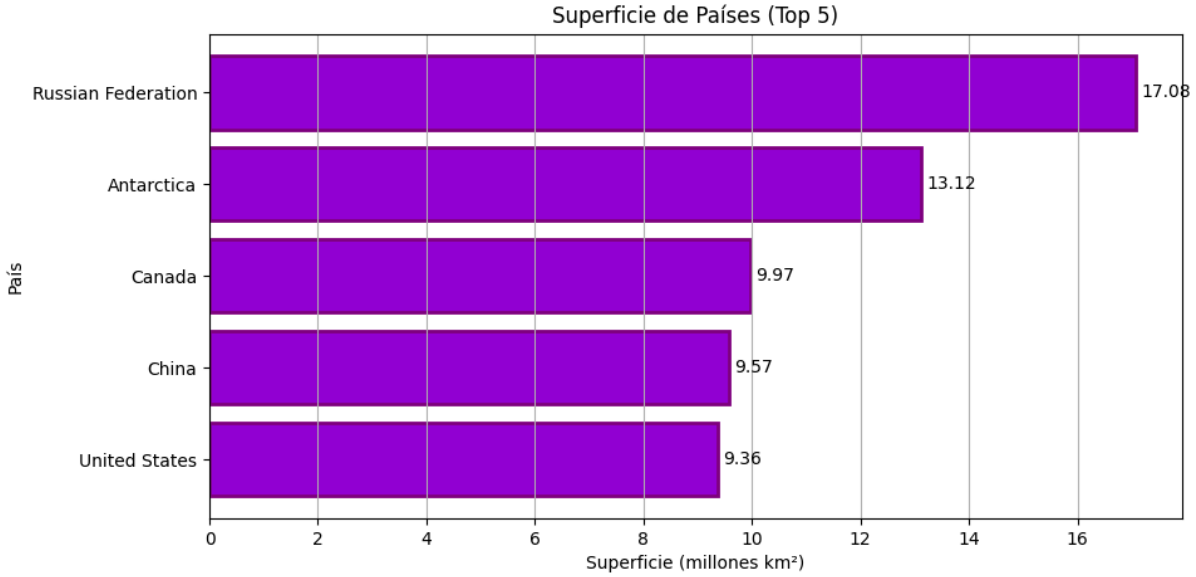

Ejercicio 3: Escribe una consulta para calcular la población total de todos los países de cada continente y mostrar el resultado junto con el nombre del continente.

```
consulta_sql3 = "SELECT Continent as Continente,sum(population) as
PoblacionTotal FROM country GROUP BY continent ORDER BY sum(population)
DESC;"

data_frame3 = obtener_datos_sql(consulta_sql3)
if data_frame3 is not None:
    print(data_frame3)
```

```
Conexión exitosa a la base de datos
Conexión cerrada
      Continente PoblacionTotal
0           Asia     3705025700
1         Africa      784475000
2         Europe      730074600
3  North America      482993000
4  South America      345780000
5        Oceania       30401150
6     Antarctica              0
```

Creamos una nueva columna dividiendo "***PoblacionTotal***" por 1.000.000 para representar mejor la escala del gráfico.

```
data_frame3['PoblacionTotal_Millones'] = data_frame3['PoblacionTotal'] /
1000000
```

```
data_frame3 = data_frame3.sort_values(by='PoblacionTotal',
ascending=True)
```

```
plt.figure(figsize=(10, 5))
barras = plt.barh(data_frame3['Continente'],
data_frame3['PoblacionTotal_Millones'], color='darkviolet', edgecolor =
"purple", linewidth = 2)
plt.title('Población Total por Continente')
plt.xlabel('Continente')
plt.ylabel('Población Total (millones)')

# etiquetas en las barras
for b in barras:
    xval = b.get_width()
    plt.text(xval + 25, b.get_y() + b.get_height()/2, f"{xval:.2f}",
ha='left', va='center')
```

```
plt.grid(axis='x')
plt.show()
```

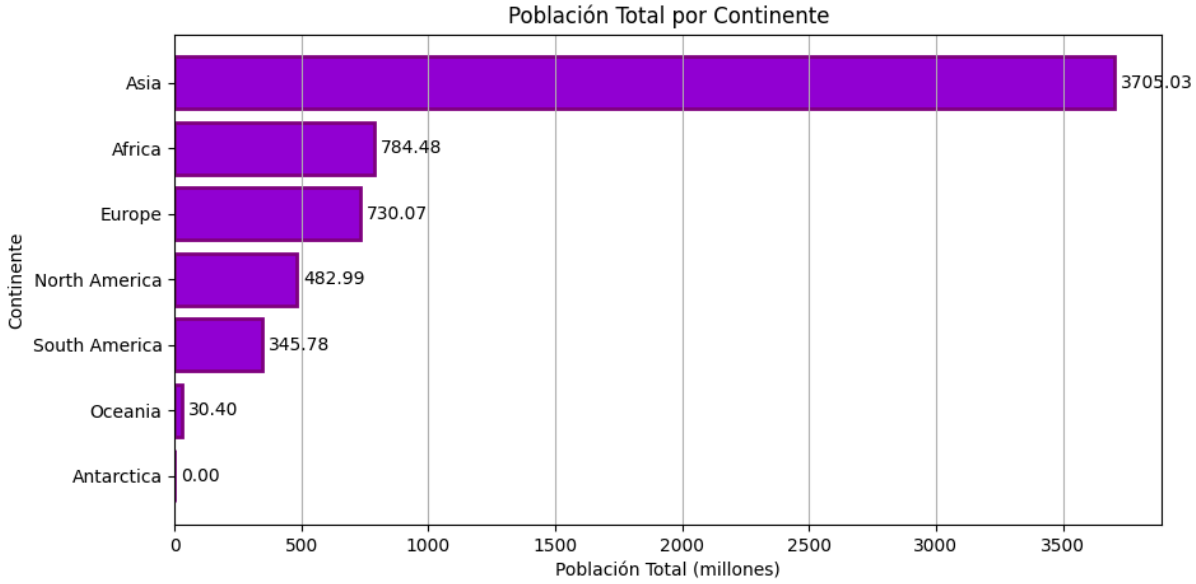

Ejercicio 4: Escribe una consulta para mostrar el nombre de las ciudades y la población de todos los países de Europa, ordenados por población de la ciudad de manera descendente.

```
consulta_sql4 = "SELECT ci.name as Ciudad, ci.population as Poblacion,
co.name as Pais FROM city as ci LEFT JOIN country as co ON
ci.countrycode = co.code WHERE co.continent = 'Europe' ORDER BY
ci.POPULATION desc"

data_frame4 = obtener_datos_sql(consulta_sql4)
if data_frame4 is not None:
    print(data_frame4)
```

```
Conexión exitosa a la base de datos
Conexión cerrada
                Ciudad  Poblacion                         Pais
0               Moscow    8389200           Russian Federation
1               London    7285000               United Kingdom
2        St Petersburg    4694000           Russian Federation
3               Berlin    3386667                      Germany
4               Madrid    2879052                        Spain
..                 ...        ...                          ...
836         Serravalle       4802                   San Marino
837          San Marino       2294                   San Marino
838        Longyearbyen       1438       Svalbard and Jan Mayen
839        Monaco-Ville       1234                       Monaco
```

```
840  Città del Vaticano        455  Holy See (Vatican City State)

[841 rows x 3 columns]
```

Para hacer un gráfico primero hacemos una nueva consulta filtrando un Top 20 de ciudades más pobladas de Europa. Luego ordenamos y creamos una nueva columna dividiendo "***Poblacion***" por 1.000.000 para representar mejor la escala del gráfico.

```
consulta_sql4_top = "SELECT ci.name as Ciudad, ci.population as
Poblacion, co.name as Pais FROM city as ci LEFT JOIN country as co ON
ci.countrycode = co.code WHERE co.continent = 'Europe' ORDER BY
ci.POPULATION desc LIMIT 20"

data_frame4_top = obtener_datos_sql(consulta_sql4_top)
if data_frame4_top is not None:
    print(data_frame4_top)
```

```
data_frame4_top['Poblacion_millones']=data_frame4_top['Poblacion']/10000
00
```

```
data_frame4_top = data_frame4_top.sort_values(by='Poblacion_millones',
ascending=True)
```

```
plt.figure(figsize=(10, 6))
barras = plt.barh(data_frame4_top['Ciudad'],
data_frame4_top['Poblacion_millones'], color='darkviolet',
edgecolor="purple", linewidth=2)
plt.title('Ciudades más pobladas de Europa (Top 20)')
plt.xlabel('Población Total (millones)')
plt.ylabel('Ciudad')

# generamos las etiquetas en las barras con un bucle
for b in barras:
    xval = b.get_width()
    plt.text(xval + 0.05, b.get_y() + b.get_height()/2, f"{xval:.2f}",
ha='left', va='center')

plt.grid(axis='x')
plt.show()
```

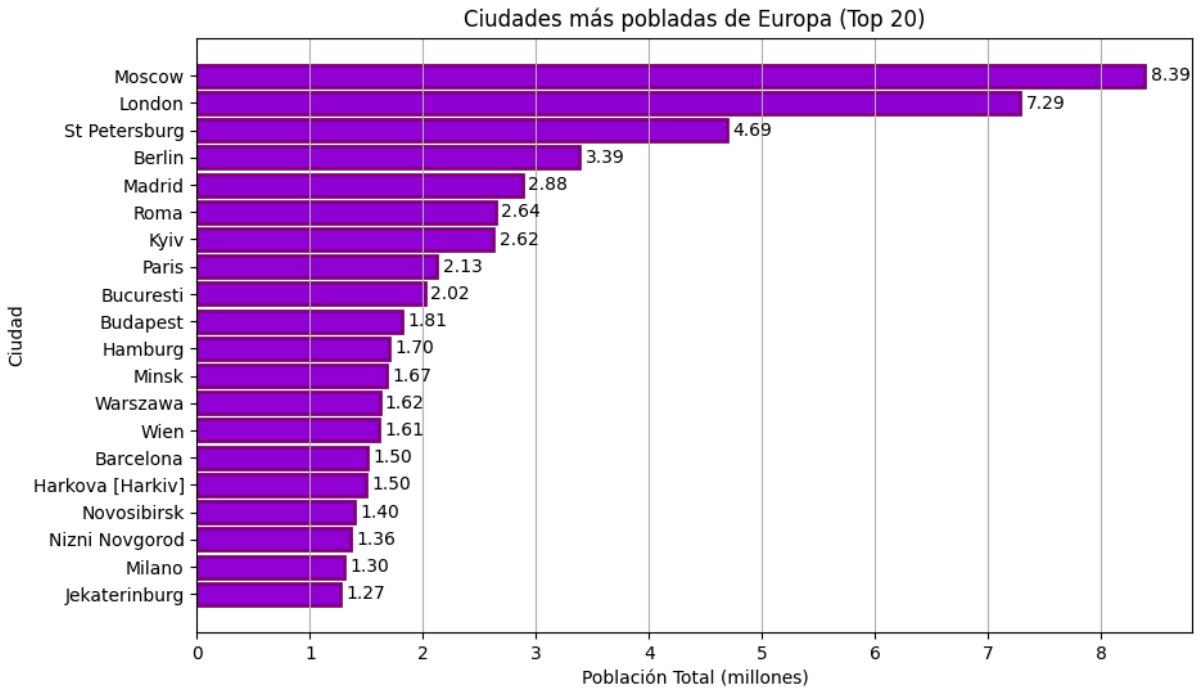

Ejercicio 5: Actualiza la población de China (código de país 'CHN') a 1500000000 (1.5 mil millones).

Primero hacemos la consulta para mostrar la población de China a través del código de país 'CHN'.

```
consulta_sql5 = "SELECT name as Pais, code as CodigoPais, population as
Poblacion FROM country WHERE code = 'CHN'"

data_frame5 = obtener_datos_sql(consulta_sql5)
if data_frame5 is not None:
    print(data_frame5)
```

```
Conexión exitosa a la base de datos
Conexión cerrada
    Pais CodigoPais   Poblacion
0  China        CHN  1277558000
```

Una vez verificada la población, utilizamos la función "***actualizar_datos_sql***" para modificar el registro de población para China. Luego volvemos a utilizar la función de consulta para verificar la modificación.

```
# (La población inicial de China era de '1277558000')

update = "UPDATE country SET population = 1500000000 WHERE code =
'CHN';"
actualizar_datos_sql(update)
```

```
data_frame5 = obtener_datos_sql(consulta_sql5)
if data_frame5 is not None:
    print(data_frame5)
```

```
Conexión exitosa a la base de datos
Datos actualizados
Conexión cerrada
Conexión exitosa a la base de datos
Conexión cerrada
    Pais CodigoPais   Poblacion
0  China        CHN  1500000000
```

Ejercicio 6: Cantidad de hablantes por idioma en Europa.

Se incluye esta consulta adicional para obtener la cantidad de hablantes por idioma en el continente europeo. Primero hacemos una consulta para unir las tablas "***country***" y "***countrylanguage***" mediante un Join, a través de los campos "***Code***" y "***CountryCode***" respectivamente. Además, partiendo de la columna "***Porcentaje***" multiplicamos por el total de población de cada país y dividimos por 100 para obtener la columna "***Hablantes_Por_Idioma***", determinando el total de hablantes por idioma por país en el mundo.

```
consulta_sql6 = "SELECT co.Name AS Pais, co.Continent AS Continente,
cl.Language AS Idioma, cl.Percentage AS Porcentaje, ROUND(co.Population
* (cl.Percentage / 100), 0) AS Hablantes_Por_Idioma FROM country co JOIN
countrylanguage cl ON co.Code = cl.CountryCode ORDER BY
ROUND(co.Population * (cl.Percentage / 100), 0)  DESC;"

data_frame6 = obtener_datos_sql(consulta_sql6)
if data_frame6 is not None:
    print(data_frame6)
```

```
       Pais                   Continente      Idioma      Porcentaje  Hablantes_Por_Idioma
0      China                  Asia            Chinese     92.0        1175353360
1      India                  Asia            Hindi       39.9        404451138
2      United States          North America   English     86.2        239943734
3      Brazil                 South America   Portuguese  97.5        165862125
4      Russian Federation     Europe          Russian     86.6        127244844
..     ...                    ...             ...         ...         ...
979    Saint Vincent and the G North America   English     0.0         0
980    Virgin Islands, British North America   English     0.0         0
981    Wallis and Futuna      Oceania         Futuna      0.0         0
982    Wallis and Futuna      Oceania         Wallis      0.0         0
983    Yemen                  Asia            Soqutri     0.0         0
```

Debido a que luego haremos más cálculos, verificamos el tipo de dato de cada columna del data frame obtenido con el método "***.info()***".

```
data_frame6.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 984 entries, 0 to 983
Data columns (total 5 columns):
 #   Column                Non-Null Count  Dtype 
---  ------                --------------  ----- 
 0   Pais                  984 non-null    object
 1   Continente            984 non-null    object
 2   Idioma                984 non-null    object
 3   Porcentaje            984 non-null    object
 4   Hablantes_Por_Idioma  984 non-null    object
dtypes: float64(2), object(3)
memory usage: 38.6+ KB
```

Cambiamos los tipos de datos de las columnas numéricas de "***object***" a "***float***" para poder hacer cálculos.

```
data_frame6['Hablantes_Por_Idioma'] =
pd.to_numeric(data_frame6['Hablantes_Por_Idioma'])
data_frame6['Porcentaje'] = pd.to_numeric(data_frame6['Porcentaje'])
```

Filtramos el data frame conservando los países del continente europeo, y los idiomas con "***Porcentaje***" mayores a 0.

```
data_frame6_mod = data_frame6[(data_frame6['Continente'] == 'Europe') &
(data_frame6['Porcentaje'] >0)]
```

Para calcular el total de población del continente europeo utilizamos una nueva consulta, generando un nuevo data frame con el total de la población por país.

```
consulta_sql_PT = "SELECT Name as Pais, Population as Poblacion FROM
country WHERE Continent = 'Europe' ORDER BY Population DESC;"

Poblacion_Paises_Europa = obtener_datos_sql(consulta_sql_PT)
if Poblacion_Paises_Europa is not None:
    print(Poblacion_Paises_Europa)
```

```
Conexión exitosa a la base de datos
Conexión cerrada
                            Pais  Poblacion
0              Russian Federation  146934000
1                         Germany   82164700
2                  United Kingdom   59623400
3                          France   59225700
4                           Italy   57680000
...                           ...        ...
41                  Liechtenstein      32300
42                     San Marino      27000
43                      Gibraltar      25000
44         Svalbard and Jan Mayen       3200
45  Holy See (Vatican City State)       1000

[46 rows x 2 columns]
```

A partir del nuevo data frame sumamos el total de población y lo asignamos en la variable "***PobTotalEuropa***".

```
PobTotalEuropa = Poblacion_Paises_Europa['Poblacion'].sum()
```

Tomamos el data frame inicial, agrupamos los datos según la columna "***Idioma***", y calculamos el total de hablantes por idioma.

```
Poblacion_Por_Idioma_Europa =
data_frame6_mod.groupby('Idioma')['Hablantes_Por_Idioma'].sum().reset_in
dex()
print(Poblacion_Por_Idioma_Europa)
```

```
                   Idioma  Hablantes_Por_Idioma
0               Albaniana             5664231.0
1                  Arabic             1897294.0
2                 Avarian              587736.0
3                 Bashkir             1028538.0
4                  Basque              631067.0
..                    ...                   ...
56                 Tatar             4701888.0
57                Turkish             3702889.0
58                  Udmur              440802.0
59              Ukrainian            35515495.0
60  Ukrainian and Russian               32392.0

[61 rows x 2 columns]
```

Calculamos dos nuevas columnas, una de ellas es "***Hablantes_Por_Idioma_%***" dividiendo la cantidad de hablantes por idioma por el total de la población europea y multiplicando por 100. La otra columna la obtenemos dividiendo "***Hablantes_Por_Idioma***" por 1.000.000.

```
Poblacion_Por_Idioma_Europa['Hablantes_Por_Idioma_%'] =
round((Poblacion_Por_Idioma_Europa['Hablantes_Por_Idioma']*100 /
PobTotalEuropa),2)
Poblacion_Por_Idioma_Europa['Hablantes_Por_Idioma_millones'] =
round(Poblacion_Por_Idioma_Europa['Hablantes_Por_Idioma']/1000000,2)
print(Poblacion_Por_Idioma_Europa)
```

Finalmente hacemos un Top 10 para cada columna, y reordenamos para representarlas gráficamente.

```
Poblacion_Por_Idioma_Europa = Poblacion_Por_Idioma_Europa.nlargest(10,
'Hablantes_Por_Idioma_%')
Poblacion_Por_Idioma_Europa = Poblacion_Por_Idioma_Europa.nlargest(10,
'Hablantes_Por_Idioma_millones')
Poblacion_Por_Idioma_Europa =
Poblacion_Por_Idioma_Europa.sort_values(by='Hablantes_Por_Idioma_millone
s', ascending=True)
```

```
plt.figure(figsize=(10, 6))
barras = plt.barh(Poblacion_Por_Idioma_Europa['Idioma'],
Poblacion_Por_Idioma_Europa['Hablantes_Por_Idioma_%'],
color='darkviolet', edgecolor="purple", linewidth=2)
plt.title('Hablantes por idioma respecto del total de Europa (Top 10)')
plt.xlabel('Porcentaje del total')
plt.ylabel('Idioma')

# generamos las etiquetas en las barras con un bucle
for b in barras:
    xval = b.get_width()
    plt.text(xval + 0.05, b.get_y() + b.get_height()/2, f"{xval:.2f}",
ha='left', va='center')

plt.grid(axis='x')
plt.show()
```

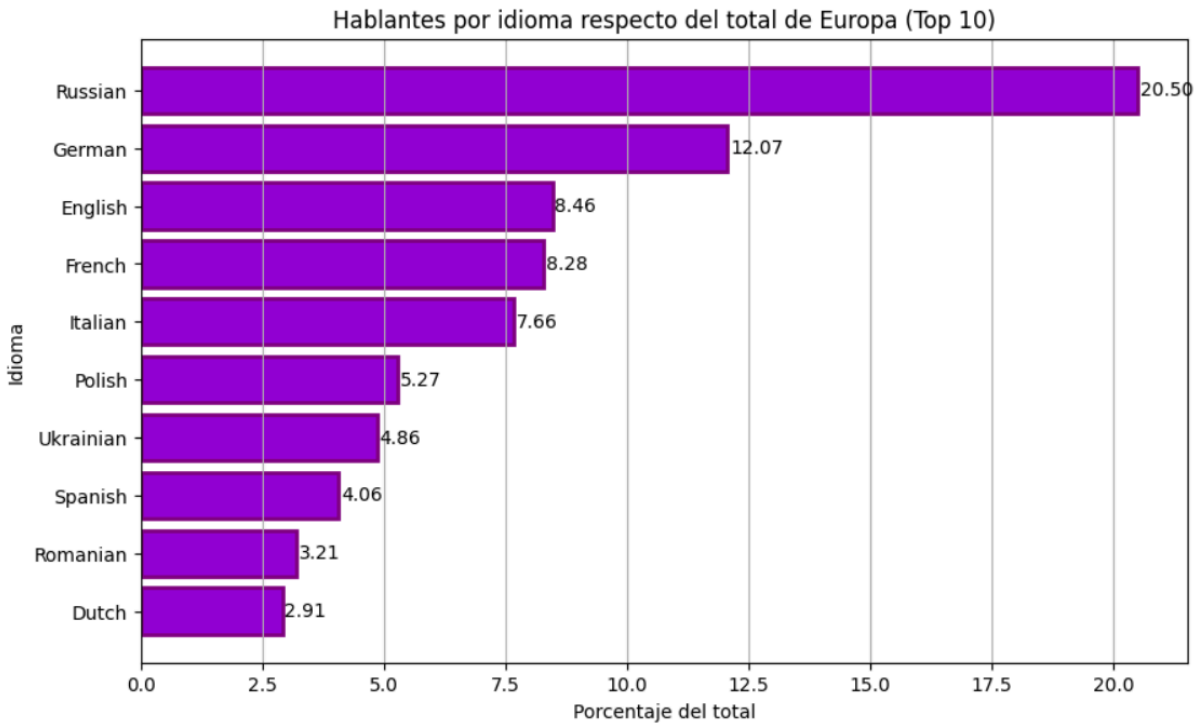


```
plt.figure(figsize=(10, 6))
barras = plt.barh(Poblacion_Por_Idioma_Europa['Idioma'],
Poblacion_Por_Idioma_Europa['Hablantes_Por_Idioma_millones'],
color='darkviolet', edgecolor="purple", linewidth=2)
plt.title('Hablantes por idioma de Europa (Top 10)')
plt.xlabel('Hablantes por idioma (millones)')
plt.ylabel('Idioma')

# generamos las etiquetas en las barras con un bucle
for b in barras:
    xval = b.get_width()
    plt.text(xval + 1, b.get_y() + b.get_height()/2, f"{xval:.2f}",
ha='left', va='center')

plt.grid(axis='x')
plt.show()
```

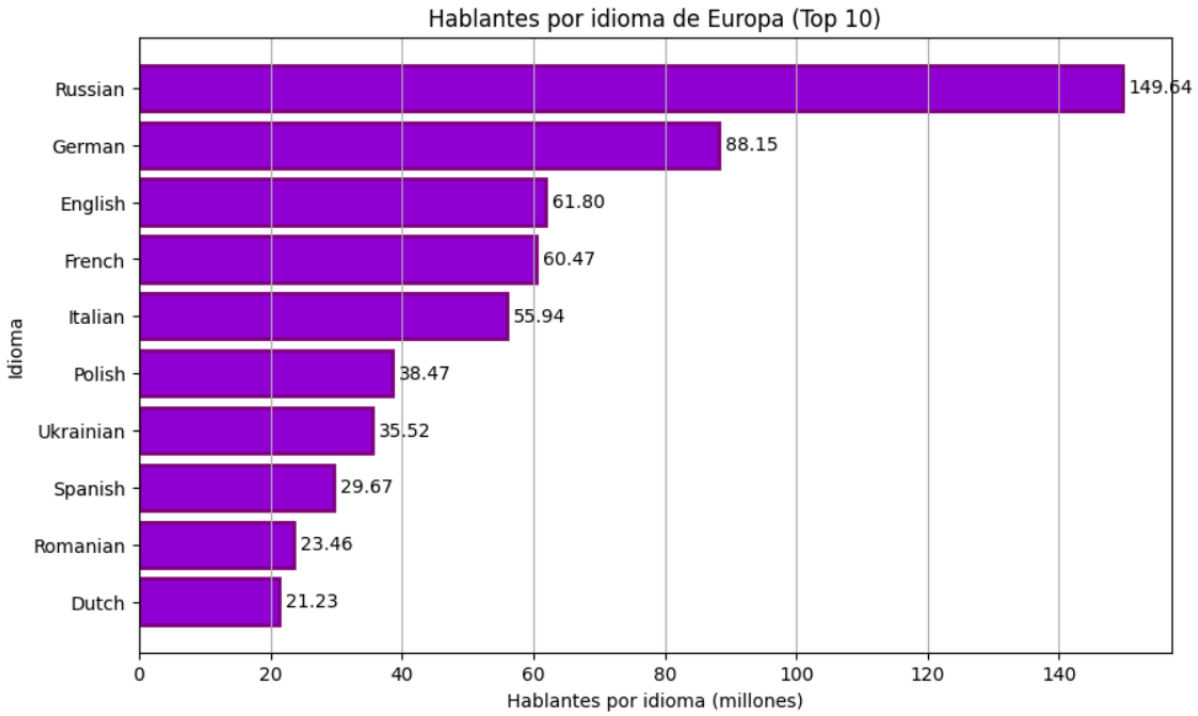

7. Consideraciones Éticas y de Privacidad

Los datos utilizados son públicos y provienen de Unicorn Academy, garantizando el cumplimiento de normativas de privacidad y uso ético. Además, se asegura un manejo responsable, preservando el anonimato y la confidencialidad.

8. Gestión del Proyecto mediante GitHub

El proyecto Datos Mundiales ha sido gestionado y organizado utilizando **GitHub** como plataforma de almacenamiento y control de versiones. Todo el código desarrollado, incluidas las consultas SQL, scripts de Python y configuraciones necesarias para el análisis de datos se encuentra almacenado en un repositorio de GitHub. Esto garantiza una estructura ordenada, facilita el acceso y asegura la trazabilidad de los cambios realizados, permitiendo también la colaboración y documentación continua del proyecto.

Repositorio: https://github.com/Debvaz2024/Proyecto-integrador-bootcamp.git

9. Conclusiones

En conclusión, el proyecto Datos Mundiales nos permitió capitalizar los conocimientos adquiridos durante el curso de Data Analytics de Unicorn Academy a través de la aplicación práctica de herramientas como SQL y Python en un entorno colaborativo.

El análisis nos ha permitido explorar y analizar datos demográficos y geográficos, con un enfoque particular en Europa, pero también presenta información relevante en términos políticos y económicos, posibilitando hacer otros tipos de análisis y estudios más diversos.

Algunos puntos interesantes que podemos destacar son los siguientes:

- Europa tiene 46 países dentro de su territorio, y una población total de 730.074.600 habitantes.
- El país con mayor extensión territorial es Rusia, ubicado en el continente europeo.
- Moscú (Rusia), Londres (Reino Unido) y San Petersburgo (Rusia) son las tres ciudades más pobladas de Europa.
- En el mundo existen 458 idiomas y dialectos nativos, de los cuales 61 son hablados en Europa, siendo el ruso (20,50%), el alemán (12,07%) y el inglés (8,46%) los 3 más hablados.

Como contraparte, este dataset presenta ciertas limitaciones. La más importante de ellas es que los datos no se encuentran actualizados. Identificamos que los datos corresponden a alrededor del año 2000, gracias al dato de Fernando de la Rúa como presidente en Argentina. Esta falta de actualización puede afectar la relevancia y aplicabilidad de nuestros hallazgos en el contexto actual.

Sin embargo, el proyecto nos ha brindado una valiosa experiencia en la manipulación y análisis de los datos propuestos, así como en la integración de diferentes herramientas, lo que nos prepara para enfrentar desafíos futuros en el campo del análisis de datos. Es fundamental considerar la importancia de trabajar con datos actualizados y de calidad para garantizar que nuestras conclusiones y recomendaciones sean efectivas y pertinentes en un mundo en constante cambio.

10. Perspectivas para el futuro

A medida que concluimos este análisis, es importante reconocer que los datos presentados son sólo una parte de un panorama mucho más amplio. Futuros estudios podrían explorar la diversidad cultural y lingüística en relación con el desarrollo económico, analizando cómo la diversidad de idiomas hablados en un país puede influir en su crecimiento y cohesión social. Además, sería interesante investigar la correlación entre indicadores económicos como el PBI y la esperanza de vida, considerando cómo el desarrollo económico de un país afecta la salud y el bienestar de las comunidades.

Estas áreas de investigación no solo ampliarían el alcance de nuestro análisis, sino que también proporcionarán información valiosa para académicos, responsables de políticas y organizaciones no gubernamentales. Por otro lado, estos datos también pueden servir de puntapié inicial para el sector privado, donde por ejemplo un análisis de territorios y de densidad poblacional pueden influir para la creación y/o establecimiento de industrias que exploten potencialmente recursos económicos, ofreciendo soluciones a las necesidades de la población a lo largo del mundo.

Links de Contacto

Lucas Gómez:

- LinkedIn: linkedin.com/in/inlucasgomez
- Correo: gomezlucasalejandroo@gmail.com

Débora Vázquez:

- LinkedIn: linkedin.com/in/deborajvazquez
- Correo: deborajpvazquez@gmail.com

Gonzalo Rey:

- LinkedIn: linkedin.com/in/reygonzaloe
- Correo: reygonzaloe@gmail.com